

# Aleatorización

Recordemos que en este curso estudiamos herramientas que nos permitan hacer inferencia causal. Con lo que hemos visto hasta ahora...

¿Por qué no podemos hacer inferencia causal con MCO?

↳ Correlación no implica causalidad

En realidad si podríamos hacer inferencia causal con una regresión lineal, sólo que necesitamos hacer un supuesto extra. Consideremos el siguiente ejemplo para ilustrar lo anterior. Nos interesa estudiar el efecto del ejercicio en el ritmo cardíaco de reposo (HR) de un individuo. Supongamos que el HR potencial de un individuo  $i$  que decide ejercitarse es lineal en la cantidad de ejercicio que, de hecho, se ejercita. Esto es:

$$HR_{ie} = \alpha + \beta e_i + \varepsilon_i \quad (1)$$

donde  $\varepsilon$  es el término de error que captura todos los demás elementos que podrían afectar al HR potencial.

¡Ojo! En realidad es imposible observar HR potencial y el HR potencial  $\neq$  HR observado.

Recordemos que nos interesa estudiar el efecto causal del ejercicio en el HR potencial que tendría una persona si ésta se ejercitara +1 vez.

$$D_i = HR_{ie(i)} - HR_{ee}$$

Si tomamos la esperanza de  $D_i$  lo que tendríamos es el efecto causal promedio en el HR potencial.

Ahora bien, como no podemos observar el HR potencial tendríamos que estimar un modelo:

$$HR_i = \alpha + \beta e_i + \varepsilon_i \quad (2)$$

¿Cuál es el problema con este modelo?

No podemos asegurar que  $HR_i \perp \varepsilon_i$ , entonces, si estimamos (2) obtendríamos una  $\beta$  sesgada.

Una manera de estimar  $\beta$  insesgada es si el ejercicio se asignara de manera aleatoria. Es decir, podemos usar regresión lineal si hay aleatoriedad porque a) elimina el sesgo de selección y b) nos permite construir una suerte de contrafactual (que nunca observamos en la realidad).

En la práctica, es muy difícil que todo sea aleatorio, entonces recurrimos al **Supuesto de independencia condicional (CIA)**. Esto es que el HR potencial es independiente del ejercicio que deciden hacer, condicional a un set de regresores.

$$HR_{ie} \perp \varepsilon_i | X_i$$

$$\hookrightarrow HR_{ie} = \alpha + \beta e_i + \varepsilon_i \quad (3)$$

Por construcción, en (3)  $\varepsilon_i$  es ortogonal a  $X_i$ , es decir  $E[\varepsilon_i | X_i] = 0$ .

Bueno, ¿y eso qué? Recordemos que queremos hacer inferencia causal entre el ejercicio y el HR potencial.

Es decir nos interesa conocer la esperanza del HR potencial si  $i$  se ejercita  $e$  veces y lo estamos tratando de obtener a partir de lo que observamos que el individuo se ejercita y el HR que tiene. CIA nos permite:

¡no quitamos porque!

$$E[HR_{ie} | X_i, e_i] = E[HR_{ie} | X_i]$$

Notemos que al hacer lo anterior, estamos descomponiendo el término de error en  $X_i$  y  $\varepsilon_i$ ; pero, al ser éstos ortogonales para que:

$$E[HR_{ie} | X_i, e_i] = E[HR_{ie} | X_i] = \alpha + \beta e_i + X_i \beta$$

lo que implica que  $\text{cov}(\varepsilon_i, X_i) = 0$

y que  $\beta$  será un estimador insesgado del cual podremos inferir causalidad.

¿y esto qué tiene que ver con aleatoriedad?

En la práctica, muchas veces no podemos inferir causalidad por problemas de selección (el tratamiento no es aleatorio) ej. la decisión de entrar al mkt laboral, tener una TdC, ir al doctor, etc.

Cuando el tratamiento es aleatorio (aun es indep. del outcome) tenemos:

$$(Y_{1i}, Y_{0i}) \perp D_i \rightarrow \text{aplicamos CIA}$$

↳ notación

Entonces tenemos que

$$E[Y_{1i} | D_i = 1] = E[Y_{1i} | D_i = 0] = E[Y_{1i}]$$

$$E[Y_{0i} | D_i = 1] = E[Y_{0i} | D_i = 0] = E[Y_{0i}]$$

Contrafactuals son idénticos  $\rightarrow$  si no hubiera habido tratamiento el grupo de tratamiento y control se hubieran comportado igual.

En este contexto, podemos estimar el efecto del tratamiento como una diferencia de medias:

$$\begin{aligned} \Delta \mu &= E[Y_{1i} | D_i = 1] - E[Y_{1i} | D_i = 0] \\ &= E[Y_{1i} | D_i = 1] - E[Y_{0i} | D_i = 0] = 0 \\ &= E[Y_{1i} | D_i = 1] - E[Y_{0i} | D_i = 0] + E[Y_{1i} | D_i = 1] - E[Y_{1i} | D_i = 1] \\ &= E[Y_{1i} | D_i = 1] - E[Y_{1i} | D_i = 1] + E[Y_{0i} | D_i = 1] - E[Y_{0i} | D_i = 0] \\ &= E[Y_{0i} | D_i = 1] - E[Y_{0i}] \end{aligned}$$

ATE = average treatment effect.

$\therefore$  la aleatorización elimina el sesgo de selección y nos permite estimar el ATE a partir de una dif. de medias obtenida por MCO.